식재료 가격 전망 서비스 — 2차 보고서: 1차 예측 모델 구축

조원: 경영정보학과 60250770 전준태, 경영정보학과 60250762 원기연

깃허브: https://github.com/joon6644/ML_26_2

1차 보고서 이후 바뀐 점

항목	1차 (10/01)	2차 (현재)	이유
타깃 사용자	개인 소비자 + 자영업자	**개인 소비자 (자취생·1인 가구)**	자영업자에게 필요한 중도매가는 축산에 없고, 원가 관리에 필요한 정확도 수준이 더 높다
예측·서비스 대상 가격	소매·중도매	**소매가** (중도매 행은 학습에만 사용)	개인 소비자가 실제로 마주하는 가격
부가 기능	유사 식재료(대체재) 추천	**이번 주 싸질 재료로 만드는 메뉴 추천** (설계)	대체재를 쓰면 레시피 자체가 바뀌어 효용이 낮다. 영양성분 군집으로는 요리 용도가 구분되지 않았다 (1차 EDA ⑧)
데이터 분할	학습 2016~2022 / 테스트 2023~2024	**학습 2016~2022 / 검증 2023~2024**	모델과 피처는 검증 기간으로만 고른다. 2025년 이후 데이터는 이번 보고서에서 쓰지 않고 최종 평가용으로 남겨 둔다

1. 예측 과제와 KPI

예측 질문: "이 식재료의 앞으로 4주 평균 소매가가 최근 일주일 평균보다 몇 % 변할까?"

사용자는 이 답을 보고 **지금 살지, 미룰지**를 결정한다. 그래서 KPI를 셋으로 둔다.

구분	KPI	정의
모델 (메인)	베이스라인 대비 RMSE 개선율	(베이스라인 RMSE − 모델 RMSE) ÷ 베이스라인 RMSE. 베이스라인 = 최근 7일 평균이 4주 동안 유지된다 (변화율 항상 0%)
모델 (보조)	**방향 정확도**	실제 변화가 ±1%를 넘은 경우, 오름·내림을 맞힌 비율
비즈니스	**예측을 따랐을 때 장보기 절약률**	주 1회 장을 보는 1인 가구가 예측을 따랐을 때, 평소처럼 살 때보다 1년 장보기 비용이 몇 % 줄었나

방향 정확도를 새로 넣은 이유는 사용자의 결정이 "얼마나"보다 **"오르나 내리나"** 에 달려 있기 때문이다. 보합 기준을 ±1% 하나로 정한 것은 점수가 아닌 판단이다. 기준을 넓히면 점수만 올라갈 뿐 자연스럽게 끊기는 지점이 없다.

---

2. 데이터 전처리

1차 보고서의 수집 데이터를 다음 순서로 가공해 분야별 학습 표 하나로 만들었다.

단계	처리	이유
가격 단위	모든 가격을 원/kg으로 환산 (개·포기·마리는 KAMIS 표준 중량)	품목 간 비교, 변화율 계산
품종 이름 변경 연결	KAMIS가 품종·등급 이름을 바꾼 20건(예: 갈치 '냉동 중품' → '국산(냉동) 中', 2022-07)을 옛 기록과 이음. 등급 기준 차이는 바뀐 직후 6주 / 직전 6주 평균 비율로 보정	그대로 두면 이력이 끊겨 새 시계열이 '이력 짧음'으로 시작하고, 연결 지점에 가짜 급등락이 생김
지역 + 전국	그날 그 지역 조사 시장 가격의 중앙값(지역 행)과 전국 중앙값(전국 행)을 한 표에	지역별 전망을 내되, 지역 데이터가 부족하면 전국으로 대신하기 위해
공표 시점 결합	월·분기·연 통계는 실제 공표일 이후에만 붙임	예측 시점에 몰랐던 값이 학습에 섞이는 미래 정보 누수 방지
결측	채우지 않음	트리 모델은 값이 비어 있는 경우를 따로 갈라 학습할 수 있다. 결측은 대부분 제공 기간 차이(가락시장 2018~, 어장환경 조사 월만)라 평균으로 채우면 없던 값을 만드는 셈이다
스케일	변환하지 않음	트리 모델은 값의 크고 작음만 본다
대상 밖 행	품목과 관계없는 분야 변수(예: 양파 행의 가축 질병)는 어떤 실제 값보다 작은 값으로 표시	트리가 '해당 없음'으로 따로 나누게 하고, 무관한 값이 신호처럼 쓰이지 않게
범주	품목·식재료 계열·소매/중도매·지역을 정수 코드로	학습 구간 기준

분야	학습 행 (2016-01~2022-12)	검증 소매 행 (2023-01~2024-12)	소매 품목
농산물	4,166,977	836,131	70
축산물	139,301	407,991	7
수산물	670,984	247,306	27

한 행은 품목 × 품종·등급 × 소매/중도매 × 지역 × 날짜 하나다. 축산은 KAMIS 지역 가격이 2022년부터 본격적으로 있어서 학습 행이 적다.

---

3. Target과 Feature

Target

y = 향후 28일 평균 가격 / 최근 7일 평균 가격 − 1

- 하루 가격은 조사 시장·날짜에 따라 튀어서 불안정하다. 그래서 기준을 오늘 하루가 아닌 최근 7일 평균으로 잡는다.
- 기간은 요일 주기를 고려해 1주일 단위로 정했다. 7일과 28일(4주)은 모든 요일이 같은 횟수로 들어가 요일 효과가 섞이지 않는다.
- 품목 간 가격 차이가 수백 배라서 변화율로 통일한다. 1,000원/kg 채소와 10만원/kg 한우를 한 모델로 학습할 수 있다.
- 화면에는 `최근 7일 평균 × (1 + 예측)`으로 되돌려 보여 준다.

Feature

1차 보고서의 원본 변수(농 99 · 축 95 · 수 119개)에서 **왜 가격에 영향을 주는지 사전 가설이 있는 변수만** 남겼다. 같은 역할을 하는 변수는 하나로 압축했다(예: 휘발유·경유·등유 → 유가 지수 하나, 기온 3종 → 평균기온). 최종 피처는 범주형 포함 **농산 42 · 축산 33 · 수산 43개**다.

구성	예시	가설
가격 이력	1주·4주·13주 변화율, 전년 대비, 28일 변동성, 오늘 가격 / 7일 평균, 작년 같은 시기 변화율	농산은 계절 반복, 축·수산은 평균 회귀 (1차 EDA ⑤)
지역	지역, 지역 프리미엄(지역 / 전국 − 1), 전국 가격 이력	지역 가격은 전국 흐름을 따라가되 지역 차이가 되돌아간다
달력	주차, 설·추석까지 남은 일수	명절 수요
농산 외부 변수	가락시장 정산가·건수·주산지 비중, 주산지 기온·강수·일조, 품목 소비자물가, 수입물가	공급 충격은 도매에서 먼저 보인다 / 날씨가 작황을 결정한다
축산 외부 변수	경락가·경락 두수, 사육 두수, 재고, 품목별 가축 질병 건수, 사료 곡물 가격	도축·재고·질병이 공급을 정한다
수산 외부 변수	도매가, 어획량, 해역 수온, 양식장 수질, 물가·환율·유가 변화율	어획과 수온이 공급을, 유가가 비용을 정한다

---

4. 모델: RandomForest

모델	역할	설정
베이스라인	넘어서야 할 기준	변화율 0% (최근 7일 평균 유지)
RandomForest	1차 예측 모델	트리 100개, 잎 최소 50행, 피처 50%씩, 트리마다 학습 행 10%씩 표본

회귀로 푼 이유. "오르냐 내리냐"만 보면 분류로도 풀 수 있다. 하지만 서비스는 예상 가격(최근 7일 평균 × (1 + 예측))을 보여 줘야 하고, 같은 '상승'이라도 +2%와 +20%는 사용자의 결정이 다르다. 그래서 변화율을 회귀로 예측하고, 방향은 예측값의 부호(±1% 기준)로 읽는다.

RandomForest를 첫 모델로 고른 이유는 다음과 같다.

- 가격 변화는 "많이 올랐을 때만 되돌아온다"처럼 조건부다. 트리는 이런 비선형·상호작용을 따로 지정하지 않아도 학습한다.
- 결측이 많은 외부 변수를 채우지 않고 그대로 쓸 수 있고, 스케일 변환이 필요 없다.
- 트리를 독립적으로 여러 개 만들어 평균하므로 설정에 덜 민감하다. 첫 모델로 기준선을 잡기에 알맞다.
- 학습 행이 수백만 개라서 트리마다 10%씩 표본을 뽑아 학습한다. 학습 시간은 농산 약 2분, 수산 13초, 축산 2초다 (CPU AMD Ryzen 5 7500F 6코어 12스레드, 전체 코어 사용).

분야마다 가격 구조가 달라(1차 EDA ⑦) **분야별로 모델을 하나씩** 학습한다. 학습에는 소매·중도매 행을 함께 쓰고(소매/중도매는 범주 피처), 평가는 소매 행만 본다.

---

5. 첫 예측 결과 (검증 2023-01 ~ 2024-12, 소매)

분야	모델	RMSE	RMSE 개선	MAE	R^2	방향 정확도
농산물	베이스라인	0.1493	–	0.0939	−0.011	–
	RandomForest	**0.1170**	**21.6%**	**0.0774**	**0.379**	**0.725**
축산물	베이스라인	0.0666	–	0.0414	−0.001	–
	RandomForest	**0.0615**	**7.7%**	**0.0388**	**0.145**	**0.655**
수산물	베이스라인	0.0994	–	0.0540	−0.007	–
	RandomForest	**0.0865**	**13.0%**	**0.0510**	**0.237**	**0.691**

방향 정확도의 우연 수준은 약 0.50이다(상승·하락이 거의 반반).

결과에서 읽은 것

1. **세 분야 모두 베이스라인을 넘었다.** "가격이 그대로 간다"고 볼 때보다 예측 오차(RMSE)를 농산 21.6% · 축산 7.7% · 수산 13.0% 줄였다. 오름·내림은 0.66~0.73으로 맞혀, 우연(0.50)보다 16~23%p 높다.
2. **R^2는 0.15~0.38에 그친다.** 같은 품목이라도 지역·시장마다 따로 움직이는 잡음이 커서 4주 뒤 가격 수준을 정확히 맞히기는 어렵다. 다만 사용자의 결정에 필요한 것은 방향이고, 방향은 R^2보다 훨씬 안정적으로 맞는다.
3. **분야 차이가 크다.** 농산은 계절 반복이 뚜렷해(1차 EDA ④) 가장 잘 맞고, 축산이 가장 약하다. 축산은 4주 변화 자체가 작고(표준편차 5%), 지역 가격 학습 기간이 1년뿐이다(2022년부터).

예측이 클수록 방향이 잘 맞는다

예측 크기	농산물	축산물	수산물
1~2%	0.608	0.646	0.650
2~5%	0.674	0.735	0.731
5~10%	0.772	0.829	0.800
10% 이상	0.895	–	0.860

축산은 예측이 10%를 넘은 경우가 없었다. 모델이 "크게 오른다/내린다"고 할 때는 열에 여덟아홉이 맞고, "조금"이라고 할 때는 열에 여섯 남짓만 맞는다. 그래서 서비스는 예측값만 보여 주지 않고 **얼마나 믿을 만한 예측인지**를 함께 보여 줄 계획이다(다음 단계).

예측 예시 (검증 기간, 학습에 쓰지 않은 날짜)

```
[농산물] 배추 (여름 고랭지, 상품) · 서울 · 기준일 2023-09-15
  최근 7일 평균          2,034 원/kg
  향후 4주 평균 전망     2,433 원/kg  (+19.6%, 상승 예상)
  실제 4주 평균          2,557 원/kg  (+25.7%) → 방향 적중
```

```
[농산물] 양파 (상품) · 서울
  기준일 2024-04-12  전망 -12.0% (하락 예상)  → 실제 -14.2%  방향 적중
  기준일 2024-03-27  전망  +1.7% (상승 예상)  → 실제  -3.2%  방향 틀림
```

큰 예측은 맞았고, 작은 예측은 틀렸다. 위 표의 "예측이 작을수록 덜 맞는다"가 실제 사례에서도 그대로 보인다.

---

6. 비즈니스 관점 해석

자취생 장바구니로 본 효과 (검증 기간 2023년·2024년)

자취생이 주 1회 장을 보고, 자주 사는 재료 10가지를 매주 1주일치씩 먹는다고 가정했다. 재료는 4주 정도 보관할 수 있는 것으로, 보통 사는 형태(쌀 10kg, 계란 30구, 손질 닭 등)로 골랐다. 대파는 썰어서 냉동한다고 보았고, 우유·애호박처럼 4주 보관이 안 되는 재료는 뺐다. 가격은 그 주 최근 7일 평균 전국 소매가다.

집에 남은 양(재고)을 따라가며 계산했다. "늦게 사기"는 집에 남은 게 있을 때만 가능하기 때문이다.

행동	모델 없이	모델 사용
평소	재고를 2주치(이번 주 먹을 것 + 여유 1주)로 유지 = 매주 1주일치를 산다	같음 (예측이 ±1% 이내일 때)
미리 사기	–	'상승 예상'(+1% 초과)이면 재고를 4주치까지 채운다
늦게 사기	–	'하락 예상'(−1% 미만)이면 여유분을 쓰며 이번 주 먹을 만큼만 남기고, 싸진 뒤에 채운다

절약률 = (모델 없이 쓴 돈 − 모델을 따라 쓴 돈) ÷ 모델 없이 쓴 돈. 해마다 따로 계산했다. 연말에 집에 남은 양의 차이는 연말 가격으로 계산해 빼서, 두 경우 모두 같은 양을 먹은 것으로 맞췄다.

품목	2023 절약률	2024 절약률	1년 가격 폭 (2024, 최고 / 최저)
대파 (상품)	4.0%	3.8%	2.3배
당근 (상품)	3.1%	3.3%	2.3배
감자 (수미, 상품)	3.1%	2.5%	1.9배
양파 (상품)	0.5%	1.5%	1.6배
계란 (특란 30구)	1.1%	1.2%	1.3배
깐마늘 (국산, 상품)	1.6%	1.0%	1.3배
김 (구운김)	0.0%	0.8%	1.4배
쌀 (10kg, 상품)	0.5%	0.6%	1.2배
돼지 앞다리	0.2%	0.5%	1.2배
닭 (손질 닭, kg)	0.2%	0.3%	1.2배
장바구니 전체 (품목당 같은 금액)	**1.4%**	**1.6%**	

- **두 해 모두 비슷하게 아꼈다.** 장바구니 전체 절약률은 2023년 1.4%, 2024년 1.6%다. 1년에 이 재료들로 100만 원을 쓴다면 약 1.4만~1.6만 원이다. 품목 순위도 두 해가 거의 같아(대파·당근·감자가 위, 쌀·고기가 아래), 한 해의 우연이 아니다.
- **효과는 가격이 크게 움직이는 품목에서 크다.** 1년 사이 가격이 2배 넘게 움직인 대파·당근은 3% 넘게 아꼈고, 가격 폭이 1.2배 안팎인 쌀·고기는 1%가 안 된다. 가격이 안정적인 품목은 "평소대로 사도 된다"는 확인 자체가 정보다.
- **틀릴 때도 있다.** 검증 기간 전체에서 방향을 낸 예측의 19~23%는 반대로 움직였고, 그때 평균 4.5~7.9%를 더 냈다. 그래서 서비스는 예측을 단정하지 않고 "판단 근거"로 제공한다.
- **이 시뮬레이션은 효과의 크기를 가늠하기 위한 보수적인 기준(벤치마크)이다.** 한 품목을 매주 같은 양만큼 먹는다고 고정했고, 사는 시점만 바꿨다. 실제 장보기에서는 이번 주에 무엇을 해 먹을지, 어떤 재료를 고를지도 함께 정한다. 싸질 재료 위주로 메뉴를 고르는 선택(메뉴 추천 기능)까지 더해지면 절약 폭이 이보다 커질 여지가 있다. 다만 사람들이 추천을 보고 실제로 무엇을 사 먹을지는 알 수 없어, 이 효과는 금액으로 측정하지 않았다.

7. 사람이 내린 판단

모델은 점수를 계산할 뿐이다. 무엇을 맞힐지, 어떤 결과를 믿을지는 사람이 정했다.

판단	내용	이유
타깃 정의	하루 가격이 아닌 "향후 4주 평균 / 최근 7일 평균 − 1"	가격 자체를 타깃으로 하면 품목마다 가격이 수백 배 달라 한 모델로 비교할 수 없다. 하루 가격 기준으로 계산하면 하루짜리 등락에 흔들려 불안정해서 최근 7일 평균을 기준으로 했다. 기간은 요일 주기를 고려해 1주일 단위로 정했다. 추세는 한 달 정도는 봐야 안정적이고, 장보기를 앞당기거나 미루는 결정에 쓰기에도 4주가 적당한 길이라고 판단했다
평가 기준	R^2만 보지 않고 방향 정확도를 추가, 보합 기준은 ±1% 하나	사용자는 "몇 %"보다 "오르냐 내리냐"로 결정한다. 보합 기준은 넓힐수록 점수만 오르고 자연스럽게 끊기는 지점이 없어서, 점수가 아니라 '이 정도는 변화가 아니다'라는 판단으로 정했다
피처 채택	점수가 올라도 사전 가설이 없는 변수는 넣지 않음	월별 지표처럼 가격과 무관한 변수도 우연히 점수를 올릴 수 있다. 이유를 설명할 수 없는 변수는 시기가 바뀌면 오히려 틀리게 만든다
대상 축소	자영업자·중도매가를 빼고 개인 소비자·소매가로	축산은 중도매가 자체가 없고, 자영업자의 원가 관리에는 더 높은 정확도가 필요하다. 지금 데이터로 실제 도움을 줄 수 있는 대상에 집중했다
데이터 정합성	품종 이름이 바뀐 20건을 옛 기록과 연결	같은 상품의 이력이 이름 때문에 끊기는 것은 데이터 오류다. 끊긴 채로 두면 새 이름의 시계열이 이력 없이 시작하고, 연결 지점에 가짜 급등락이 생긴다

8. 다음 단계 (3차 보고서)

축	계획	이유
데이터	가설 3 검증: "가격 이력만" vs "+ 외부 변수", 이상치(하루짜리 튐)·결측 처리 방법 비교	외부 변수가 실제로 도움이 되는지 확인해야 매일 수집할 데이터를 정할 수 있다. 1차 모델은 이상치·결측 처리를 기본값으로 두었다
모델	선형회귀·LightGBM·XGBoost·CatBoost 비교, 분야마다 다른 모델을 쓸지 판단, 품목군별 오차 분석	축산처럼 약한 분야를 어떻게 끌어올릴지, 어디서 왜 틀리는지 알아야 다음 개선을 고를 수 있다
파라미터	트리 수·잎 크기 등 하이퍼파라미터 점검, 학습 타깃 극단값 처리	첫 모델은 설정을 하나로 고정했다. 바꿨을 때의 차이가 우연(시드) 수준을 넘는지 확인
서비스	예측 크기 → "그 방향으로 1% 넘게 움직일 확률" 표시, 지역 데이터 부족 시 표시 규칙	같은 예측이라도 얼마나 믿을지를 사용자에게 보여줘야 한다